

YOLOv5 内部数据流与参数优选实验报告

——基于 1000 张 COCO 标注图像的单因素筛选与组合验证

项 目	内 容
实验模型	YOLOv5s (yolov5s.pt)
实验数据	COCO 2017 validation 固定子集 (1000 张)
实验方法	单因素多水平筛选 + 优选参数组合复验
运行平台	Windows 11 / Python 3.11.9 / PyTorch 2.13.0+cpu
报告日期	2026 年 8 月 2 日

摘要

为系统分析 YOLOv5 推理参数的作用并形成可验证的参数组合，本实验将原 300 张 COCO 样本扩展为 1000 张带边界框标注的固定子集，在模型权重、硬件与数据完全一致的条件下，对输入尺寸 `imgsz`、置信度阈值 `conf_thres`、NMS IoU 阈值 `iou_thres` 和增强推理 `augment` 分别进行单因素多水平实验。每个参数均与基准组比较，以固定阈值条件下的 `mAP@0.5:0.95` 为主要筛选指标，再将各因素优选值组合并独立复验。筛选结果为 `imgsz=768`、`conf_thres=0.35`、`iou_thres=0.45`、`augment=False`。最终组合的 Precision、`mAP@0.5` 和 `mAP@0.5:0.95` 分别达到 0.7278、0.6190 和 0.4557，较基准组的 0.6343、0.6140 和 0.4434 有所提高；Recall 由 0.5275 降至 0.4759，推理耗时由 81.4 ms/张增加至 115.4 ms/张。结果表明，单因素筛选能够解释参数的独立影响，组合复验能够确认参数叠加后的真实表现；但所谓“最优”依赖评价目标，本实验所得组合属于 `mAP@0.5:0.95` 优先方案，而不是速度或召回率优先方案。

关键词：YOLOv5；COCO；单因素实验；参数优选；组合验证；目标检测

1 引言

目标检测参数之间同时存在精度、召回率和计算量权衡。若一次改变多个参数，只能观察组合效果，无法判断具体贡献；若只研究一个参数却不复验组合，又无法确认各优选值叠加后是否仍然有效。因此，本实验采用两阶段方法：第一阶段每次只改变一个参数并设置多个水平；第二阶段汇总各因素的优选值，构成最终组合并重新运行完整验证。

2 YOLOv5 结构与参数作用位置

2.1 网络与数据流

YOLOv5s 推理流程为：读取原图 → Letterbox 缩放填充 → 归一化并组成批张量 → Backbone 提取特征 → Neck 进行 P3/P4/P5 多尺度融合 → Detect Head 产生候选框 → 置信度筛选 → NMS 抑制重复框 → 坐标还原和结果保存。实验权重融合后模型包含 213 层、7,225,885 个参数，计算量约 16.4 GFLOPs。

2.2 四个实验参数

`imgsz` 决定进入网络的空间分辨率，增大后可能保留更多小目标细节，同时提高计算量；`conf_thres` 位于候选框筛选阶段，越高则输出越保守；`iou_thres` 位于 NMS

阶段，控制重叠框被抑制的严格程度；`augment` 开启后会对同一图像进行额外变换推理并融合结果，通常显著增加耗时。

3 COCO1000 数据集构建

数据来自 COCO 2017 validation 官方集合。扩展过程保留原 COCO300 的全部 300 张图像，再从其余有效图像中使用固定扩展种子随机抽取 700 张，形成 1000 张固定样本。最终包含 7754 个非 crowd 有效边界框，覆盖 80 个 COCO 类别。COCO 格式边界框被转换为 YOLO 归一化格式，并验证 1000 张图片均可正常解码、图片与标签一一对应、类别编号位于 0~79、坐标位于 0~1；校验错误数为 0。`manifest.csv` 记录每张图像的 ID、来源地址和抽样来源。




图 1 COCO1000 子集中实例数最多的 15 个类别

4 实验方法

4.1 控制变量与水平设置

所有实验均固定 `yolov5s.pt`、同一 1000 张图像、CPU 设备、`batch size=4` 和最大检测数 1000。基准参数为 `imgsz=640`、`conf=0.25`、`IoU=0.45`、`augment` 关闭。单因素阶段在任一组中只改变一个参数，其余参数保持基准值。

表 1 单因素实验设计

因素	测试水平	对应组别	其余条件
基准	640 / 0.25 / 0.45 / Off	A	固定模型与数据
<code>imgsz</code>	512、640、768	S1、A、S2	<code>conf=0.25</code> , <code>IoU=0.45</code> , <code>Aug=Off</code>
<code>conf_thres</code>	0.15、0.25、0.35	S3、A、S4	<code>imgsz=640</code> , <code>IoU=0.45</code> ,

			Aug=Off
iou_thres	0.35、0.45、0.55	S5、A、S6	imgsz=640, conf=0.25, Aug=Off
augment	Off、On	A、S7	imgsz=640, conf=0.25, IoU=0.45

4.2 优选规则

每个因素在其候选水平中选择 $mAP@0.5:0.95$ 最高者；若该指标相同，则选择推理耗时更低者。随后将四个优选值组合为 Z 组并重新验证。该规则代表严格定位精度优先，因此还必须并列报告 Precision、Recall、 $mAP@0.5$ 、保存检测数和速度，防止把单指标优选误解为所有维度都更好。

5 单因素实验结果

表 2 全部实验结果

组	配置变化	P	R	mAP50	mAP50-95	ms/图
A	基准	0.6343	0.5275	0.6140	0.4434	81.4
S1	imgsz=512	0.6395	0.5110	0.6055	0.4397	54.6
S2	imgsz=768	0.6444	0.5362	0.6188	0.4450	122.7
S3	conf=0.15	0.6410	0.5339	0.6090	0.4314	80.0
S4	conf=0.35	0.7210	0.4753	0.6185	0.4541	81.6
S5	IoU=0.35	0.6414	0.5246	0.6146	0.4432	79.0
S6	IoU=0.55	0.6194	0.5291	0.6102	0.4404	82.4
S7	augment=On	0.6356	0.5298	0.6102	0.4380	188.4
Z	最终组合	0.7278	0.4759	0.6190	0.4557	115.4




图 2 四类参数的单因素精度与耗时变化

5.1 输入尺寸

imgsz 从 640 降至 512 后，mAP@0.5:0.95 由 0.4434 降至 0.4397，推理耗时由 81.4 降至 54.6 ms/张；增至 768 后主指标升至 0.4450，耗时增至 122.7 ms/张。因此精度优先规则选择 768，而速度优先场景可选择 512。

5.2 置信度阈值

conf=0.15、0.25、0.35 对应的主指标分别为 0.4314、0.4434、0.4541。0.35 同时将 Precision 提高到 0.7210，但 Recall 降至 0.4753，保存检测数从基准的 6442 个减少到 5065 个。它过滤了较多低置信度候选，因此适合精度优先而非召回优先。

5.3 NMS IoU 阈值

IoU=0.35、0.45、0.55 的主指标分别为 0.4432、0.4434、0.4404，差异较小，基准值 0.45 略高，因此无需为了组合而强行修改该参数。

5.4 增强推理

开启 augment 后主指标由 0.4434 降至 0.4380，推理耗时由 81.4 增至 188.4 ms/张。该数据子集和当前 CPU 环境下没有获得精度收益，因此最终组合保持关闭。

6 优选参数组合及复验

表 3 各因素优选值及最终组合

参数	候选水平	优选值	依据组
imgsz	512 / 640 / 768	768	S2: 0.4450
conf_thres	0.15 / 0.25 / 0.35	0.35	S4: 0.4541
iou_thres	0.35 / 0.45 / 0.55	0.45	A: 0.4434
augment	Off / On	Off	A: 0.4434

最终 Z 组配置为 imgsz=768、conf=0.35、IoU=0.45、augment 关闭。复验得到 Precision=0.7278、Recall=0.4759、mAP@0.5=0.6190、mAP@0.5:0.95=0.4557。相对基准，主指标提高 0.0123（相对提高 2.8%），Precision 提高 0.0935；但 Recall 下降 0.0516，推理耗时增加 41.7%。组合后的 0.4557 高于任一单因素组，说明本次优选值叠加后仍产生了小幅正向效果，但提升不是各单因素增量的简单相加。





图3 基准组与最终参数组合的指标、检测数和速度对比



(a) 基准组 PR 曲线

(b) 最终组合 PR 曲线

图4 基准组与最终组合 PR 曲线



(a) 真实标注

(b) 最终组合预测

图5 最终组合在同一验证批次上的标注与预测

7 讨论与实验限制

第一，最终组合是按 $mAP@0.5:0.95$ 筛选的精度优先配置，并非速度、Recall 或综合成本最优。若应用更怕漏检， $conf=0.35$ 可能不合适；若要求 CPU 实时性， $imgsz=512$ 更实用。第二，单因素法假设先在基准附近独立筛选，再验证组合，能够解释主效应，但不能穷尽参数之间的全部交互；更严格研究可在优选区域继续做网

格或正交实验。第三，实验使用 COCO 验证集 1000 张固定子集而非完整 5000 张，虽覆盖 80 类但类别分布仍不均衡。

第四，本实验为观察实际推理阈值，将 `conf` 设为 0.15~0.35，高于官方 COCO AP 评测通常使用的低候选阈值；候选框会在计算曲线前被截断，因此报告中的 mAP 属于本实验固定阈值条件下的内部比较，不能直接作为官方 COCO 排行榜成绩。第五，本实验没有训练或微调模型，所得组合只改变推理配置，不会生成新的 `best.pt`。

8 进一步分析、复现性与有效性讨论

8.1 数据集构建的可复现细节

COCO1000 不是从网络随意收集的无标注图片，而是从 COCO 2017 validation 的 instances_val2017.json 中筛选得到。构建程序首先排除没有有效非 crowd 边界框的图像，保留原实验的 300 张样本，再从剩余候选图像中按固定扩展种子抽取 700 张。每个图像 ID、文件名、尺寸、目标数量、类别集合、官方来源地址和抽样来源都记录在 manifest.csv 中。因此，只要保留标注 JSON、随机种子和清单，即可重建完全相同的数据子集。

COCO 边界框格式为 $[x, y, w, h]$ ，其中 (x, y) 是左上角坐标。转换为 YOLO 格式时使用： $x_center=(x+w/2)/W$ ， $y_center=(y+h/2)/H$ ， $w_norm=w/W$ ， $h_norm=h/H$ ； W 和 H 分别为原图宽高。转换后逐行校验类别编号和四个归一化坐标，并逐张解码图片验证文件完整性。

表 4 COCO1000 构建与校验统计

项目	数值	说明
候选有效图像	4952	含有效非 crowd 目标
最终图像	1000	原 300 张+新增 700 张
目标实例	7754	平均 7.75 个/图
覆盖类别	80	COCO 全部 80 类
person 实例	2261	占全部实例 29.2%
校验错误	0	图片、标签和坐标检查

表 5 COCO1000 实例数最多的 10 个类别

序号	类别	实例数	涉及图像数	实例占比
1	person	2261	542	29.16%
2	car	396	110	5.11%
3	chair	394	118	5.08%
4	book	263	47	3.39%
5	cup	223	82	2.88%
6	bottle	205	66	2.64%
7	dining table	152	102	1.96%
8	bowl	141	64	1.82%
9	bird	122	28	1.57%
10	traffic light	117	39	1.51%

类别分布具有明显长尾特征：person 单类占全部实例约 29.2%，而部分稀有类别只有少量实例。整体指标因此更容易受到常见类别影响；即使总体 mAP 提高，也不能据此断言每个类别都同步改善。报告保留 per-class mAP 数组，可用于后续按类别检查参数收益。

8.2 网络张量尺寸与候选框数量

输入图像经过 Letterbox 调整为方形张量[B, 3, H, W]，像素由 0~255 归一化到 0~1。Backbone 中的步长为 2 的卷积连续下采样，Neck 再通过上采样和 Concat 融合浅层定位信息与深层语义信息。Detect Head 最终在 P3、P4、P5 三个尺度输出预测。对于 80 类 COCO 模型，每个锚框预测 4 个框坐标、1 个目标置信度和 80 个类别分数。

表 6 基准输入与最终输入的特征图尺寸

阶段	典型模块	步长	640 输入尺寸	768 输入尺寸	YOLOv5s 通道
输入	Letterbox/归一化	1	640×640	768×768	3
Stem	Conv	2	320×320	384×384	32
浅层	Conv+C3	4	160×160	192×192	64
P3	C3/Detect	8	80×80	96×96	128
P4	C3/Detect	16	40×40	48×48	256
P5	SPPF/C3/Detect	32	20×20	24×24	512

在 3 个锚框/网格位置的设置下，640 输入对应 $(80^2+40^2+20^2) \times 3 = 25,200$ 个原始候选位置；768 输入对应 $(96^2+48^2+24^2) \times 3 = 36,288$ 个，候选位置增加 44%。这解释了 S2 和最终组合在保留更多空间细节的同时，需要更长前向推理时间。NMS 只处理置信度筛选后的候选框，因此 conf 提高会减少后处理输出，却不会显著减少网络主体的卷积计算。

8.3 评价指标、匹配方法与阈值关系

预测框与真实框通过 IoU 衡量重叠程度： $\text{IoU} = \text{交集面积} / \text{并集面积}$ 。当类别一致且 IoU 达到评价阈值时，匹配预测记为 TP；错误类别、定位不足或重复预测记为 FP；未被匹配的真实目标记为 FN。由此有 $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$ ， $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$ ， $\text{F1} = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$ 。

PR 曲线通过改变置信度工作点得到；AP 是单个类别 PR 曲线下的面积，mAP 是各类别 AP 的平均值。mAP@0.5 只在 IoU=0.5 评价，较宽松；mAP@0.5:0.95 在 0.50、0.55.....0.95 共 10 个阈值上平均，对边界框位置更敏感。因此本实验以 mAP@0.5:0.95 作为主筛选指标，同时报告 P、R、mAP50 和速度。

需要区分两个 IoU 概念：评价 IoU 决定预测框是否与真实框匹配；命令行 iou_thres 则用于 NMS，决定两个同类预测框重叠到什么程度时抑制其中一个。conf_thres 在 PR 曲线统计前过滤候选框，本实验使用 0.15~0.35 用于研究实际输出行为，因此所得 mAP 是阈值条件下的内部结果，不等同于使用低候选阈值的官方 COCO AP。

8.4 各单因素相对基准的定量变化

表 7 各实验相对基准组 A 的变化量

组	变化	ΔP	ΔR	ΔmAP_{95}	$\Delta ms/图$	检测框	平均 conf
S1	imgsz=512	+0.0053	-0.0165	-0.0037	-26.8	6026	0.5814
S2	imgsz=768	+0.0102	+0.0088	+0.0016	+41.3	6591	0.5717
S3	conf=0.15	+0.0067	+0.0064	-0.0119	-1.4	9071	0.4663
S4	conf=0.35	+0.0867	-0.0522	+0.0108	+0.2	5065	0.6542
S5	IoU=0.35	+0.0071	-0.0029	-0.0002	-2.4	6298	0.5827
S6	IoU=0.55	-0.0149	+0.0016	-0.0030	+1.0	6641	0.5704
S7	augment=On	+0.0013	+0.0023	-0.0054	+107.0	7787	0.5676
Z	最终组合	+0.0935	-0.0516	+0.0123	+33.9	5119	0.6511




图 6 各组精度指标相对基准的变化热力图




图 7 九组实验的精度—速度分布

S1 把输入缩小到 512，推理时间减少 26.8 ms/张，约快 32.9%，但主指标下降 0.0037；S2 把输入增至 768，主指标提高 0.0016，推理时间增加 50.7%。这表明输入尺寸的精度收益相对有限，而计算成本变化明显。若目标是 CPU 部署，S1 虽然没有最高 mAP，却可能具有更高工程价值。


S4 的 $\text{conf}=0.35$ 产生最明显的单因素主指标增益：Precision 提高 0.0867，Recall 下降 0.0522，保存检测框减少 1377 个，平均置信度由 0.5776 升至 0.6542。这并不是模型学到了更好的特征，而是输出门槛提高后，低分候选被过滤。S5 和 S6 说明 NMS IoU 在 0.35~0.55 范围内影响较小；S7 增强推理不仅没有提高主指标，耗时还增加约 131.4%。

8.5 最终组合的叠加效应与工程解释


最终组合实际主指标增益为 0.012341。若简单相加 $\text{imgsz}=768$ 的单因素增益 0.001639 与 $\text{conf}=0.35$ 的单因素增益 0.010780，预期增益为 0.012420；实际值与其差异为 -0.000078。在本次子集上二者近似相加，但该差值很小，可能处于抽样和运行波动范围内，不能据此断言参数间不存在交互。

从输出行为看，最终组合保存 5119 个检测框，比基准少 1323 个（减少 20.5%）；平均置信度由 0.5776 升至 0.6511。按纯推理耗时估算，吞吐率由约 12.28 张/秒降至 8.67 张/秒。最终组合适合误报成本较高且允许一定速度损失的离线分析，不适合作为所有场景的统一默认值。

8.6 混淆矩阵与 F1 曲线解读



(a) 基准组混淆矩阵



(b) 最终组合混淆矩阵

图 8 基准组与最终组合的混淆矩阵

混淆矩阵用于观察类别识别和背景误判：主对角线表示类别预测正确，非对角元素表示类别混淆，背景相关行列反映漏检和误检。由于 COCO 包含 80 类且本子集类别不均衡，矩阵适合定位具体错误来源，而不应仅凭颜色深浅判断总体优劣。




图 9 基准组与最终组合的 F1—置信度曲线

F1 曲线反映 Precision 与 Recall 的综合平衡随置信度阈值变化的情况。曲线峰值对应当前数据上的较优折中工作点，但实际部署阈值仍应根据业务成本确定：安全检测通常更重视 Recall，自动告警或人工复核成本较高的任务可能更重视 Precision。

8.7 有效性威胁与改进方案

表 8 实验有效性威胁及改进建议

有效性问题	对结论的影响	建议改进
同一数据筛选并复验	最终成绩可能存在选择偏差	划分独立验证集和测试集
类别长尾	总体指标偏向常见类别	报告每类 AP 并对稀有类补样
每组只运行一次	速度和小幅精度差异含随机波动	每组重复 3~5 次并报告均值/方差
仅 CPU 平台	速度结论不能直接外推 GPU	在 RTX 4070 上复现实验
高 conf 条件计算 mAP	不能作为官方 COCO 榜单成绩	另以 conf=0.001 执行标准 AP 评测
单因素水平有限	可能错过更优区间和参数交互	在优选附近做网格或正交实验
未训练模型	只优化输出行为，未改变特征能力	专用任务需划分数据并微调模型

更严格的下一阶段实验可将 1000 张样本划分为 700 张参数筛选集和 300 张独立测试集。先在 700 张上完成单因素与组合选择，参数冻结后只在 300 张测试集运行一次；同时以 conf=0.001 计算标准 mAP，再另外用业务 conf 统计固定工作点的 P、R、F1 和输出数量。这样可以把模型能力评测与部署阈值分析分开。

8.8 可复现实验命令

表 9 各实验组核心命令参数

组	用途	变化参数
---	----	------

A	基准	--imgsz 640 --conf-thres 0.25 --iou-thres 0.45
S1	输入 512	--imgsz 512 --conf-thres 0.25 --iou-thres 0.45
S2	输入 768	--imgsz 768 --conf-thres 0.25 --iou-thres 0.45
S3	conf 0.15	--imgsz 640 --conf-thres 0.15 --iou-thres 0.45
S4	conf 0.35	--imgsz 640 --conf-thres 0.35 --iou-thres 0.45
S5	IoU 0.35	--imgsz 640 --conf-thres 0.25 --iou-thres 0.35
S6	IoU 0.55	--imgsz 640 --conf-thres 0.25 --iou-thres 0.55
S7	增强推理	--imgsz 640 --conf-thres 0.25 --iou-thres 0.45 --augment
Z	最终组合	--imgsz 768 --conf-thres 0.35 --iou-thres 0.45

所有命令的共同前缀为: `python val.py --data data/coco1000.yaml --weights yolov5s.pt --batch-size 4 --device cpu --max-det 1000 --save-txt --save-conf`。不同组再追加表 9 中的参数, 并分别设置 `--project runs/val` 和唯一 `--name`。完整机器可读指标保存在 `runs/val/coco1000_metrics.json` 中。

9 结论

本实验在 1000 张 COCO 标注图片上完成了基准、7 组单因素对照和 1 组最终组合复验。结果选择 `imgsz=768`、`conf=0.35`、`IoU=0.45`、`augment` 关闭, 最终 `mAP@0.5:0.95` 达到 0.4557, 相对基准提高 2.8%, 同时 `Precision` 明显提升; 代价是 `Recall` 下降和推理耗时增加 41.7%。实验说明, 参数优选应先通过单因素对照解释作用, 再通过组合复验确认叠加效果, 并始终根据实际任务在精确率、召回率、定位质量和速度之间选择。

参考文献

- [1] Lin T Y, Maire M, Belongie S, et al. Microsoft COCO: Common Objects in Context[C]//ECCV. 2014: 740-755.
- [2] COCO Consortium. COCO 2017 Detection Dataset[EB/OL]. <https://cocodataset.org/dataset/detection-2017.htm>.
- [3] Redmon J, Divvala S, Girshick R, Farhadi A. You Only Look Once: Unified, Real-Time Object Detection[C]//CVPR. 2016: 779-788.
- [4] Ultralytics. YOLOv5 Repository[EB/OL]. <https://github.com/ultralytics/yolov5>.

附录 A 数据与实验输出地址

数据集: C:\Users\31107\Desktop\datasets\coco1000

数据配置: C:\Users\31107\Desktop\yolov5\data\coco1000.yaml

数据清单: C:\Users\31107\Desktop\datasets\coco1000\manifest.csv

指标汇总: C:\Users\31107\Desktop\yolov5\runs\val\coco1000_metrics.json

实验日志: C:\Users\31107\Desktop\yolov5\runs\val\coco1000_experiment_console.log

输出目录: C:\Users\31107\Desktop\yolov5\runs\val\coco1000_*

最终组合等价命令: python val.py --data data/coco1000.yaml --weights yolov5s.pt --
imgsz 768 --conf-thres 0.35 --iou-thres 0.45 --batch-size 4 --device cpu --save-txt --save-
conf --project runs/val --name coco1000_Z_final_combined